Evaluasi Generative Pre-trained Transformer dalam Ekstraksi Fitur untuk Model Regresi Logistik dalam Deteksi Email Spam

UUNG UNGKAWA, Dr. Ir. MT,
MOCHAMAD REVI ALFIANSYAH
Program Studi Informatika, Institut Teknologi Nasional
Email: mochamad.revi@mhs.itenas.ac.id
Received XX Februari YYYY | *Revised* DD Maret YYYY | *Accepted* DD September YYYY

ABSTRAK

Deteksi email spam merupakan tantangan dalam pengelolaan komunikasi digital baik dimasa lalu, masa kini, maupun masa mendatang. Model regresi logistik sering digunakan untuk klasifikasi email spam karena kesederhanaannya dan fleksibilitasnya. Namun, efektivitasnya sangat bergantung pada kualitas fitur yang digunakan. Penelitian ini mengeksplorasi penerapan Generative Pre-trained Transformer (GPT) dalam ekstraksi fitur untuk meningkatkan performa model regresi logistik dalam mendeteksi email spam. GPT digunakan untuk mengekstrak fitur kontekstual dari teks email, yang kemudian diintegrasikan ke dalam model regresi logistik sebagai representasi fitur yang lebih bermakna. Eksperimen dilakukan dengan membandingkan performa model regresi logistik berbasis fitur GPT dan tanpa ekstraksi fitur Hasil penelitian menunjukkan bahwa pendekatan berbasis GPT memberikan peningkatan akurasi dan daya klasifikasi dibandingkan metode konvensional. Dengan demikian, penelitian ini menunjukkan bahwa pemanfaatan model bahasa besar seperti GPT dapat meningkatkan kualitas fitur dalam deteksi email spam menggunakan regresi logistik.
Kata Kunci: deteksi spam, regresi logistik, ekstraksi fitur, Generative Pre-trained Transformer (GPT), pemrosesan bahasa alami

ABSTRACT

Spam email detection has been a challenge in digital communication management in the past, present, and future. Logistic regression models are commonly used for spam email classification due to their simplicity and flexibility. However, their effectiveness heavily depends on the quality of the extracted features. This study explores the application of Generative Pre-trained Transformer (GPT) for feature extraction to enhance the performance of logistic regression in spam email detection. GPT is utilized to extract contextual features from email text, which are then integrated into the logistic regression model as more meaningful feature representations. Experiments were conducted by comparing the performance of logistic regression models using GPT-based features with and without feature. The results indicate that the GPT-based approach improves accuracy and classification capability compared to conventional methods. Thus, this study demonstrates that leveraging large language models like GPT can enhance feature quality in spam email detection using logistic regression.
Keywords: spam detection, logistic regression, feature extraction, Generative Pre-trained Transformer (GPT), natural language processing.

1. PENDAHULUAN

Email Spam merupakan ancaman dunia maya yang signifikan, karena penipu menggunakan berbagai taktik untuk mengelabuhi individu agar membocorkan informasi sensitif atau mengunduh konten berbahaya. Misalnya, pada bulan Juni 2023, Indonesia menghadapi sekitar 6,51 ribu serangan Spam, yang menunjukkan luasnya permasalahan ini. Serangan-serangan ini sering kali melibatkan strategi penipuan, seperti peniruan identitas atau janji hadiah palsu, untuk menjerat korban yang tidak menaruh curiga[9]. Di bidang keamanan siber, Spam terus menjadi ancaman yang signifikan karena para penipu menerapkan taktik yang semakin canggih untuk menipu individu dan membahayakan informasi sensitif. Meskipun ada kemajuan signifikan dalam klasifikasi Spam, metode saat ini sering kali kesulitan menyeimbangkan akurasi, efisiensi, dan kemampuan beradaptasi. Tantangan ini diperburuk oleh sifat Spam yang dinamis, taktik yang terus berkembang yang digunakan oleh penipu, dan banyaknya email yang dipertukarkan setiap hari.[9]

Regresi logistik adalah salah satu metode yang sering digunakan dalam klasifikasi email spam karena kesederhanaannya serta kemampuannya dalam memberikan interpretasi yang jelas terhadap hasil klasifikasi [10]. Namun, kinerjanya sangat bergantung pada kualitas fitur yang digunakan dalam proses klasifikasi. Oleh karena itu, pemilihan metode ekstraksi fitur yang tepat menjadi aspek yang krusial dalam meningkatkan akurasi deteksi email spam.

Dalam beberapa tahun terakhir, perkembangan Natural Language Processing (NLP) telah menghadirkan model berbasis deep learning seperti Generative Pre-trained Transformer (GPT), yang mampu mengekstrak fitur teks dengan lebih kaya dan kontekstual. GPT dapat menangkap makna dan hubungan antar kata dalam teks, sehingga berpotensi meningkatkan akurasi dalam mendeteksi email spam.

Generative Pre-trained Transformer (GPT) adalah model bahasa berbasis deep learning yang dikembangkan untuk memahami dan menghasilkan teks dengan kualitas tinggi [11]. GPT dapat menangkap informasi kontekstual dan hubungan antar kata dalam teks dengan lebih baik dibandingkan metode ekstraksi fitur tradisional seperti TF-IDF. Keunggulan ini menjadikan GPT sebagai kandidat yang menjanjikan untuk meningkatkan representasi fitur dalam klasifikasi email spam.

Dalam berbagai penelitian, penggunaan GPT telah terbukti meningkatkan akurasi model machine learning dalam berbagai tugas NLP, termasuk klasifikasi teks dan deteksi anomali [12]. Oleh karena itu, penerapan GPT dalam ekstraksi fitur untuk regresi logistik dalam deteksi email spam diharapkan dapat memberikan peningkatan performa yang signifikan dibandingkan dengan metode konvensional.

Penelitian ini bertujuan untuk membandingkan performa model regresi logistik dalam deteksi spam dengan dan tanpa ekstraksi fitur menggunakan GPT. Dengan mengevaluasi sejauh mana penggunaan GPT dapat meningkatkan efektivitas deteksi spam, penelitian ini diharapkan dapat memberikan wawasan mengenai manfaat integrasi model bahasa besar dalam model regresi logistik untuk tugas klasifikasi teks.

2. METODE PENELITIAN

2.1 Perancangan Penelitian

Pada penelitian ini dibagi menjadi beberapa langkah seperti pada blok diagram gambar 1 menunjukan proses pengumpulan dataset dan sampai dengan langkah terakhir yang menghasilkan output dari analisis hasil dan kesimpulan penelitian.

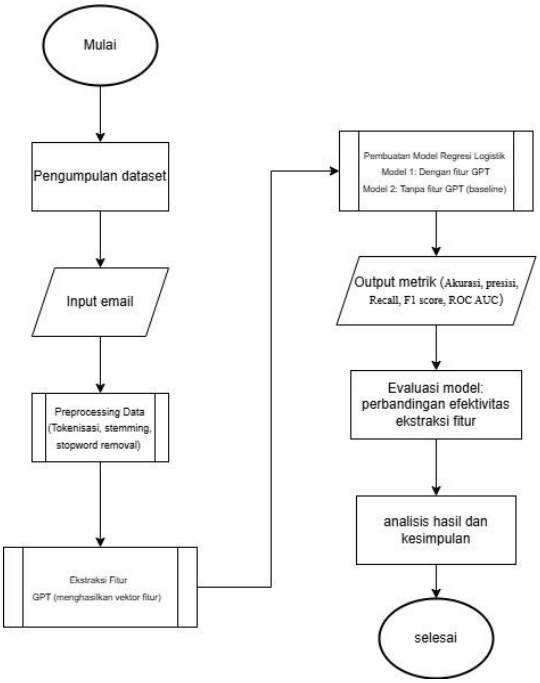

Gambar 1. Blok diagram alur penelitian

2.2 Proses penelitian

Pada Gambar 2 menunjukan proses penelitian yang terbagi menjadi 3 bagian yaitu:

1. Input: Pada input ini terdapat dataset email spam
2. Proses: pada proses penelitian ini dilakukan tahap preprosessing, ekstraksi fitur, lalu data yang telah di ekstraksi dibagi menjadi 2 bagian yaitu 80% menjadi data latih dan 20% menjadi data uji. Kemudian pada data latih dilakukan regresi logistic untuk dijadikan sebagai model, dan data uji akan masuk pada tahap model untuk melihat hasil evaluasi nya
3. Output: pada output penelitain ini, menghasilkan model yang telah dievaluasi

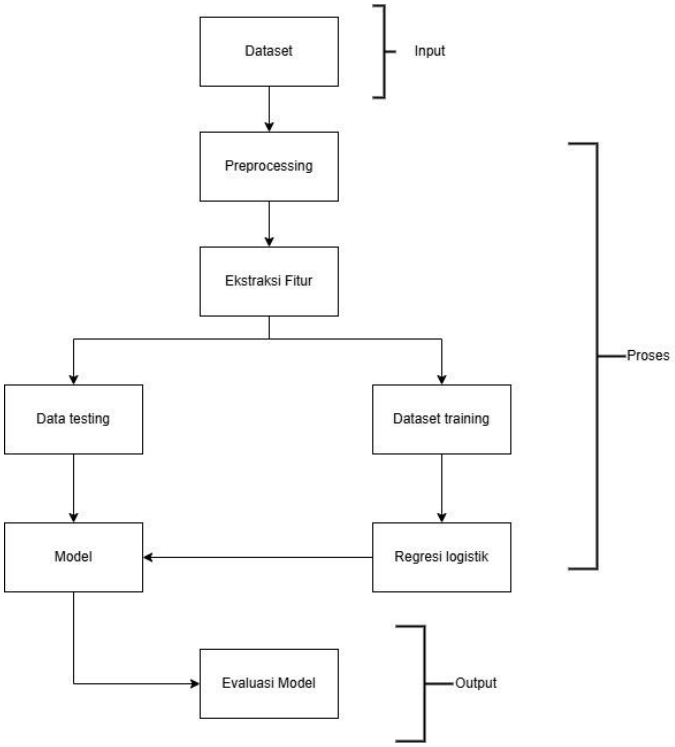

Gambar 2. Blok diagram proses penelitian

2.3 Dataset

Nama Dataset	Kelas	Total
Spam ham dataset	Spam (1)	3670
Spam ham dataset	Ham(0)	1499
	Total data	5170

Dataset yang digunakan dalam penelitian ini adalah dataset Spam Mails Dataset yang tersedia di platform Kaggle (Venkatesan, 2020). Dataset ini berisi data email yang dikategorikan ke dalam dua kelas: spam dan ham (non-spam). Dataset ini dipilih karena memiliki data yang cukup besar dan representatif dalam konteks deteksi spam email, serta dapat digunakan untuk melakukan ekstraksi fitur dan prediksi menggunakan model machine learning.

Dataset Spam Mails terdiri dari sekitar 5.000 email yang terbagi menjadi dua kategori:
• Spam: Email yang dianggap tidak diinginkan atau berisi iklan, penipuan, atau informasi yang tidak relevan.
• Ham: Email yang dianggap sah dan berisi informasi yang relevan untuk penerima

2.4 Preprocessing

Tokenisasi adalah proses memecah teks menjadi bagian-bagian kecil yang disebut token. Token ini dapat berupa kata, kalimat, atau simbol. Dalam kasus email, tokenisasi

akan membantu memecah isi email menjadi kata-kata atau simbol yang lebih mudah dianalisis

Stemming adalah teknik untuk mengubah kata-kata menjadi bentuk dasar atau akar katanya. Hal ini dilakukan untuk mengurangi variasi kata-kata yang memiliki makna yang sama. Sebagai contoh, kata "running", "runner", dan "ran" akan diproses menjadi bentuk dasar "run".

Stopword Removal adalah proses menghapus kata-kata umum yang sering muncul dalam teks tetapi tidak memberikan informasi penting untuk analisis, seperti "the", "is", "and", dan "in". Stopwords ini umumnya tidak membantu dalam membedakan kategori teks, seperti spam dan ham.

2.5 Ekstraksi Fitur

1. Pemrosesan teks oleh gpt

Setelah email dikonversi menjadi token, GPT akan memprosesnya menggunakan arsitektur Transformer yang terdiri dari beberapa lapisan self-attention**.** Setiap token harus diubah menjadi vektor numerik agar dapat diproses oleh GPT. Representasi ini disebut word embeddings, yang merupakan vektor berdimensi tinggi yang menyimpan informasi tentang makna kata dan hubungan antar kata.

a. Embedding Token ke Representasi Vektor

Setiap token dikonversi menjadi vektor berdimensi tinggi menggunakan Embedding Layer:

$$E_t = W_e \cdot T_t$$

di mana:

- Et adalah embedding dari token ke-t
- We adalah matriks embedding
- Tt adalah indeks token dalam vocabulary

b. positional Encoding

GPT tidak memiliki pemahaman tentang urutan kata secara alami seperti model RNN, sehingga informasi posisi kata dalam teks harus ditambahkan. Ini dilakukan

menggunakan positional encoding, yaitu vektor tambahan yang menunjukkan posisi kata dalam kalimat.

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{2i/d}}\right)$$
$$PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{2i/d}}\right)$$

di mana:

- pos adalah posisi kata dalam kalimat
- i adalah indeks dimensi embedding
- d adalah dimensi embedding

Positional encoding ini dijumlahkan dengan embedding awal**.** Karena Transformer tidak memiliki struktur sekuensial seperti RNN, kita harus menambahkan positional encoding ke embedding setiap token. Contoh Perhitungan Positional Encoding Misalkan untuk token "won" di posisi ke-3 dengan dimensi 3:

$$PE(3,0) = \sin\left(\frac{3}{10000^{0/3}}\right) = 0.0003$$
$$PE(3,1) = \cos\left(\frac{3}{10000^{1/3}}\right) = 0.985$$
$$PE(3,2) = \sin\left(\frac{3}{10000^{2/3}}\right) = 0.125$$

Kemudian hasil positional encoding ini ditambahkan ke embedding awal.

c. Self-Attention untuk Menangkap Konteks Teks

Self-attention adalah mekanisme yang memungkinkan setiap kata dalam teks untuk melihat dan memahami hubungan dengan kata lainnya, tidak hanya kata di dekatnya. GPT menggunakan Scaled Dot-Product Attention untuk menghitung relevansi antara kata-kata dalam teks. Fungsi dari self-attention adalah memungkinkan model memahami hubungan antar kata di seluruh teks

GPT menggunakan mekanisme self-attention (Scaled Dot-Product Attention) untuk memahami hubungan antara kata-kata dalam email. Perhitungannya sebagai berikut:

1. Menghitung Query, Key dan value

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

di mana:

- Q,K,V adalah matriks query, key, dan value yang dihasilkan dari input embeddings X.
- WQ,WK,WV adalah matriks bobot yang dipelajari.

2. Menghitung skor attention

$$A = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Skor ini menentukan seberapa relevan setiap kata dalam teks dengan kata lainnya.

Attention output untuk "won": [0.75, 0.38]

Ini berarti kata "won" lebih dipengaruhi oleh kata "free" dibandingkan kata lain.

3. Multi-Head Attention: Beberapa attention heads digunakan untuk menangkap berbagai hubungan kontekstual.

3. Ekstraksi fitur akhir dari GPT

Setelah beberapa lapisan Transformer, GPT menghasilkan representasi akhir dari teks email dalam bentuk vektor fitur. Biasanya, vektor yang digunakan adalah representasi dari token (jika menggunakan arsitektur yang memiliki token khusus untuk keseluruhan teks), atau bisa juga menggunakan rata-rata dari semua token:

$$F_{\text{email}} = \frac{1}{N}\sum_{i=1}^{N} h_i$$

di mana:

- hi adalah vektor keluaran GPT untuk token ke-i.
- N adalah jumlah token dalam teks email.

Hasilnya adalah vektor berdimensi tetap yang bisa digunakan sebagai input ke model regresi logistik.

F_email = [0.52, -0.13, 0.68, 0.45, -0.02, 0.99]

Ini adalah vektor fitur yang mewakili isi email.

Angka-angka dalam vektor ini, seperti [0.45, 0.67, -0.23, 0.52, 0.89, -0.14], berasal dari hasil transformasi dan pembaruan informasi pada tiap token yang telah diproses oleh model. Setiap angka ini merepresentasikan dimensi dari ruang vektor yang lebih tinggi, dan biasanya, dimensi ini sangat banyak (misalnya 768, 1024, atau lebih, tergantung ukuran model GPT).

Angka-angka ini tidak berasal dari proses manual, tetapi hasil perhitungan otomatis yang dilakukan oleh model GPT. Setiap angka dalam vektor menunjukkan **a**ktivasi atau kontribusi dari fitur tertentu yang dipelajari oleh model selama pelatihan, terkait dengan pemahaman dan konteks dari teks yang dimasukkan.

Proses numerik ini melibatkan banyak parameter yang dipelajari selama pelatihan, seperti bobot pada tiap koneksi dalam jaringan saraf, yang kemudian dihitung untuk menghasilkan vektor ini.

4. Penggunaan fitur dalam model regresi logistik.

Setelah mendapatkan vektor fitur Femail , kita bisa menggunakannya sebagai input ke model regresi logistik untuk deteksi spam:

$$P(y = 1|X) = \sigma(W^T F_{\text{email}} + b)$$

di mana:

- P(y=1|X) adalah probabilitas email diklasifikasikan sebagai spam.
- σ(x)= adalah fungsi aktivasi sigmoid.
- W adalah bobot model regresi logistik.
- b adalah bias.

Jika probabilitas P(y=1|X) lebih dari 0.5, maka email dikategorikan sebagai spam, jika tidak, maka email dianggap bukan spam.

2.6 Evaluasi kinerja model

Model Perhitungan Evaluasi Kinerja Model

Untuk mengevaluasi kinerja model klasifikasi seperti regresi logistik pada tugas deteksi email spam, kita biasanya menggunakan beberapa metrik berikut:

1. Akurasi: Mengukur persentase prediksi yang benar (spam atau ham) dari seluruh data yang digunakan untuk menilai seberapa baik model dalam mengklasifikasi data.

$$\text{Akurasi} = \frac{TP + TN}{TP + TN + FP + FN}$$

TP = True Positive (jumlah prediksi benar positif)

TN = True Negative (jumlah prediksi benar negatif)

FP = False Positive (jumlah prediksi negatif yang salah)

FN = False Negative (jumlah prediksi positif yang salah)

2. **Precision**: Mengukur berapa banyak dari prediksi spam yang benar-benar spam.

$$\text{Precision} = \frac{TP}{TP + FP}$$

Di mana:

- TP (True Positives) adalah jumlah spam yang benar diklasifikasikan sebagai spam.
- FP (False Positives) adalah jumlah ham yang salah diklasifikasikan sebagai spam.

3. **Recall**: Mengukur berapa banyak email spam yang berhasil ditemukan oleh model.

$$\text{Recall} = \frac{TP}{TP + FN}$$

Di mana:

- FN (False Negatives) adalah jumlah email spam yang salah diklasifikasikan sebagai ham.

4. **F1 Score**: Harmonik rata-rata dari precision dan recall. Berguna ketika kita perlu mempertimbangkan keseimbangan antara precision dan recall.

$$\text{F1 Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

5. **ROC AUC**

   ROC (Receiver Operating Characteristic) adalah kurva yang menggambarkan performa model klasifikasi dengan memplot True Positive Rate (TPR) terhadap False Positive Rate (FPR) pada berbagai threshold.

   AUC (Area Under Curve) adalah luas di bawah kurva ROC, yang menunjukkan kemampuan model untuk membedakan antara kelas positif (spam) dan kelas negatif (non-spam).

ROC curve dibentuk dengan menghitung TPR dan FPR pada berbagai threshold klasifikasi.

$$TPR = \frac{TP}{TP + FN}$$

Ini mengukur seberapa banyak email non-spam yang salah diklasifikasikan sebagai spam.

False Positive Rate (FPR):

$$FPR = \frac{FP}{FP + TN}$$

Ini mengukur seberapa banyak email non-spam yang salah diklasifikasikan sebagai spam.

Perhitungan AUC
AUC adalah luas di bawah kurva ROC dan dihitung dengan pendekatan trapezoidal rule:

$$AUC = \sum_{i=1}^{n-1} (x_{i+1} - x_i) \times \frac{(y_i + y_{i+1})}{2}$$

di mana:

- xi adalah nilai FPR pada threshold ke-i,
- yi adalah nilai TPR pada threshold ke-i.

Interpretasi Nilai AUC:

- 0.5 → Model tidak lebih baik dari tebakan acak.
- 0.7 - 0.8 → Model memiliki performa yang cukup baik.
- 0.8 - 0.9 → Model memiliki performa yang baik.
- > 0.9 → Model sangat baik dalam membedakan spam dan non-spam.
- 1.0 → Model sempurna (biasanya overfitting).

3. HASIL DAN PEMBAHASAN

3.1 Hasil Ekstraksi Fitur

Pada gambar 3 dibawah ini menunjukkan tampilan dataset yang telah diekstraksi fiturnya menggunakan Generative Pre-trained Transformer (GPT). Setiap baris dalam dataset ini mewakili email yang telah dikonversi menjadi representasi numerik berdasarkan fitur yang diekstraksi dari teks email. Kolom pertama kemungkinan merupakan label atau identitas email, sedangkan kolom-kolom berikutnya berisi nilai numerik yang menggambarkan karakteristik email tersebut. Proses ekstraksi fitur ini memungkinkan model machine learning untuk memahami pola dalam teks dan melakukan analisis lebih lanjut, seperti prediksi atau deteksi spam dalam penelitian ini.

Gambar 3. Hasil email yang sudah diekstraksi fitur

3.2 Hasil Dengan Ekstraksi Fitur

Tabel 1 Hasil Regresi dengan gpt

1.	Akurasi	0.9758
2.	Presisi	0.9557
3.	Recall	0.9590
4.	F1 Score	0.9574
5	ROC AUC	0.9935

Tabel 1 menampilkan hasil evaluasi model yang menggunakan Generative Pre-trained Transformer (GPT) untuk ekstraksi fitur dalam model regresi logistik yang digunakan untuk deteksi email spam. Berikut adalah penjelasan untuk setiap metrik yang disajikan dalam tabel:

1. **Akurasi (Accuracy)**: Nilai akurasi adalah 0.9758, yang berarti model ini dapat mengklasifikasikan email spam dan non-spam dengan benar sekitar 97.58% dari total data. Ini menunjukkan bahwa model memiliki performa yang sangat baik dalam mengidentifikasi email spam.
2. **Presisi (Precision)**: Nilai presisi adalah 0.9557. Presisi mengukur seberapa banyak email yang diklasifikasikan sebagai spam benar-benar adalah spam. Nilai ini menunjukkan bahwa sekitar 95.57% dari email yang diklasifikasikan sebagai spam oleh model adalah benar-benar spam.
3. **Recall**: Nilai recall adalah 0.9590. Recall mengukur seberapa banyak email spam yang berhasil diidentifikasi oleh model dari total email spam yang ada. Nilai ini menunjukkan bahwa model dapat mengidentifikasi sekitar 95.90% dari semua email spam.
4. **F1 Score**: Nilai F1 Score adalah 0.9574. F1 Score adalah rata-rata harmonik dari presisi dan recall, yang memberikan gambaran keseimbangan antara kedua metrik tersebut. Nilai ini menunjukkan bahwa model memiliki keseimbangan yang baik antara presisi dan recall.
5. **ROC AUC**: Nilai ROC AUC adalah 0.9935. ROC AUC mengukur kemampuan model untuk membedakan antara email spam dan non-spam. Nilai yang mendekati 1 menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam membedakan kedua kelas tersebut.

Secara keseluruhan, tabel ini menunjukkan bahwa model yang menggunakan GPT untuk ekstraksi fitur dalam regresi logistik memiliki performa yang sangat baik dalam deteksi email spam, dengan nilai-nilai metrik yang tinggi di semua kategori.

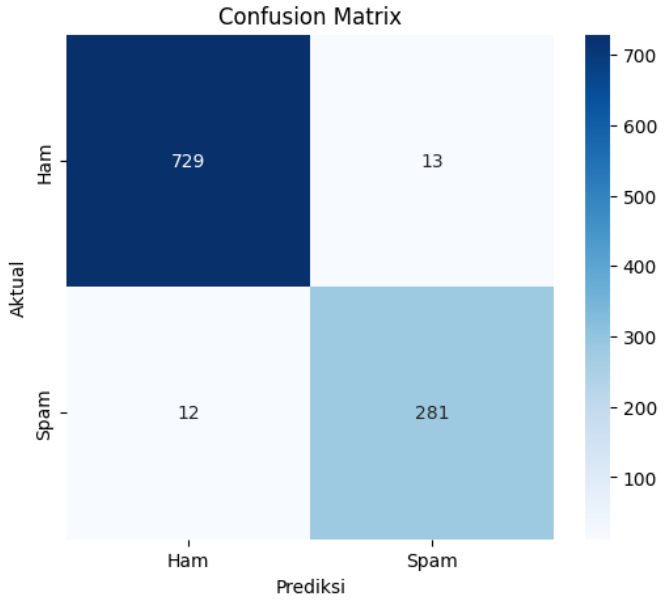

Gambar 4 Distribusi nilai actual vs prediksi

Gambar 4 ini menyajikan hasil evaluasi kinerja model regresi logistik dalam mendeteksi email spam, dengan memanfaatkan fitur yang diekstrak menggunakan model Generative Pre-trained Transformer (GPT). Confusion matrix digunakan untuk memahami seberapa baik model klasifikasi bekerja dalam memprediksi kategori yang benar.

Elemen-Elemen Gambar:

- Sumbu Horizontal (Prediksi): Menunjukkan prediksi model terhadap email, apakah email tersebut diprediksi sebagai "Ham" (bukan spam) atau "Spam".
- Sumbu Vertikal (Aktual): Menunjukkan kategori email yang sebenarnya, apakah email tersebut termasuk dalam kategori "Ham" atau "Spam".
- Angka dalam Kotak:
    - 729: Jumlah email yang sebenarnya "Ham" dan juga diprediksi sebagai "Ham" oleh model (True Negative).
    - 13: Jumlah email yang sebenarnya "Ham" tetapi diprediksi sebagai "Spam" oleh model (False Positive).
    - 12: Jumlah email yang sebenarnya "Spam" tetapi diprediksi sebagai "Ham" oleh model (False Negative).
    - 281: Jumlah email yang sebenarnya "Spam" dan juga diprediksi sebagai "Spam" oleh model (True Positive).
- Warna: Warna pada kotak-kotak menunjukkan jumlah email dalam kategori tersebut, dengan gradasi warna biru yang menunjukkan skala nilai.

Interpretasi:

- Model ini memiliki kinerja yang baik dalam mengklasifikasikan email "Ham", dengan 729 email yang terklasifikasi dengan benar sebagai "Ham" (True Negative) dan hanya 13 email yang salah diklasifikasikan sebagai "Spam" (False Positive).
- Model ini juga cukup baik dalam mengklasifikasikan email "Spam", dengan 281 email yang terklasifikasi dengan benar sebagai "Spam" (True Positive) dan 12 email yang salah diklasifikasikan sebagai "Ham" (False Negative).

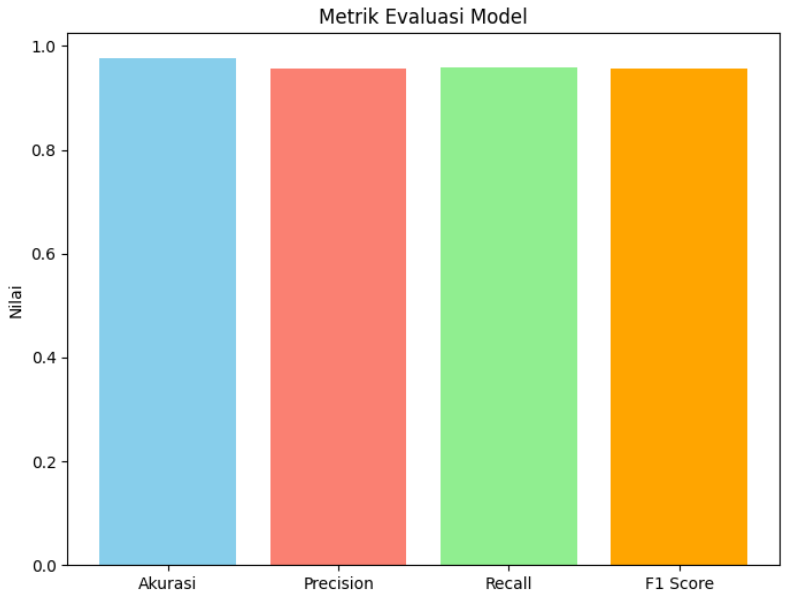

Gambar 5 metrik evaluasi model

Interpretasi:

- Akurasi (Accuracy): Mencapai nilai mendekati 1.0, yang berarti model memiliki tingkat akurasi yang sangat tinggi dalam memprediksi data dengan benar.
- Presisi (Precision): Juga mendekati 1.0, menunjukkan bahwa model memiliki tingkat presisi yang sangat baik dalam memprediksi data positif dengan tepat.
- Recall: Mendekati 1.0, artinya model mampu mengidentifikasi sebagian besar data positif dengan benar.
- F1 Score: Mendekati 1.0, ini adalah harmonic mean dari presisi dan recall, yang mengindikasikan bahwa model memiliki keseimbangan yang baik antara presisi dan recall.

Berdasarkan pada gambar 5 ini, dapat disimpulkan bahwa model klasifikasi ini memiliki kinerja yang sangat baik. Semua metrik evaluasi menunjukkan nilai yang sangat tinggi, mendekati 1.0. Hal ini menandakan bahwa model ini akurat, presisi, memiliki kemampuan identifikasi yang baik (recall), dan keseimbangan yang baik antara presisi dan recall (F1 Score).

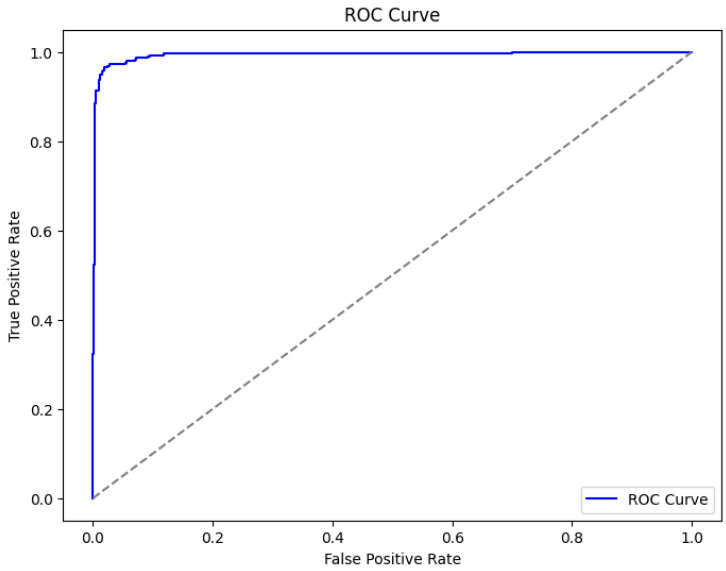

Gambar 6 ROC Curve

Interpretasi:

- Kurva ROC pada gambar menunjukkan peningkatan yang tajam pada *True Positive Rate* (TPR) dengan sedikit peningkatan *False Positive Rate* (FPR). Ini adalah indikasi bahwa model memiliki kinerja yang baik dalam mengklasifikasikan data positif dengan benar tanpa banyak melakukan kesalahan klasifikasi data negatif sebagai positif.
- Kurva ROC yang cembung ke atas (menjauhi garis diagonal) menunjukkan bahwa model memiliki kemampuan diskriminasi yang baik.
- Area di bawah kurva ROC (AUC - Area Under the Curve) akan memberikan nilai kuantitatif kinerja model. Semakin besar area di bawah kurva (mendekati 1), semakin baik kinerja model.

Berdasarkan kurva ROC ini, dapat disimpulkan bahwa model klasifikasi memiliki kinerja yang sangat baik dalam memisahkan antara kelas positif dan negatif. Kurva yang curam dan area di bawah kurva yang luas mengindikasikan bahwa model ini memiliki sensitivitas dan spesifisitas yang tinggi.

3.2 Hasil Tanpa Ekstraksi fitur

Tabel 2 Hasil Regresi tanpa ekstraksi fitur

1.	Akurasi	0.7227
2.	Presisi	0.7142
3.	Recall	0.3412
4.	F1 Score	0.6514
5	ROC AUC	0.5365

Tabel 2 menampilkan hasil evaluasi model yang tanpa ekstraksi fitur Generative Pre-trained Transformer (GPT). Berikut adalah penjelasan untuk setiap metrik yang disajikan dalam tabel:

1. **Akurasi (Accuracy)**: Nilai akurasi adalah 0.7227, yang berarti model ini dapat mengklasifikasikan email spam dan non-spam dengan benar sekitar 72.27% dari total data. Ini menunjukkan bahwa model memiliki performa yang kurang begitu baik dalam mengidentifikasi email spam.
2. **Presisi (Precision)**: Nilai presisi adalah 0.7142. Presisi mengukur seberapa banyak email yang diklasifikasikan sebagai spam benar-benar adalah spam. Nilai ini menunjukkan bahwa sekitar 71.42% dari email yang diklasifikasikan sebagai spam oleh model adalah benar-benar spam.
3. **Recall**: Nilai recall adalah 0.3412. Recall mengukur seberapa banyak email spam yang berhasil diidentifikasi oleh model dari total email spam yang ada. Nilai ini menunjukkan bahwa model dapat mengidentifikasi sekitar 34.12% dari semua email spam.
4. **F1 Score**: Nilai F1 Score adalah 0.6514. F1 Score adalah rata-rata harmonik dari presisi dan recall, yang memberikan gambaran keseimbangan antara kedua metrik tersebut.
5. **ROC AUC**: Nilai ROC AUC adalah 0.0614. ROC AUC mengukur kemampuan model untuk membedakan antara email spam dan non-spam. Nilai yang tidak mendekati 1 menunjukkan bahwa model memiliki kemampuan yang kurang begitu baik dalam membedakan kedua kelas tersebut.

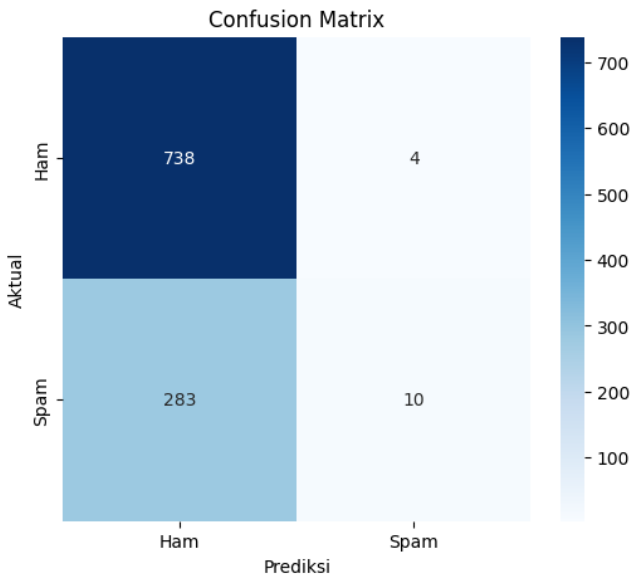

Gambar 7 Distribusi nilai actual vs prediksi

Gambar 7 ini menyajikan hasil evaluasi kinerja model regresi logistik dalam mendeteksi email spam, tanpa menggunakan fitur ekstraksi. Confusion matrix digunakan untuk memahami seberapa baik model klasifikasi bekerja dalam memprediksi kategori yang benar.

Elemen-Elemen Gambar:

- Sumbu Horizontal (Prediksi): Menunjukkan prediksi model terhadap email, apakah email tersebut diprediksi sebagai "Ham" (bukan spam) atau "Spam".
- Sumbu Vertikal (Aktual): Menunjukkan kategori email yang sebenarnya, apakah email tersebut termasuk dalam kategori "Ham" atau "Spam".
- Angka dalam Kotak:
    - 738: Jumlah email yang sebenarnya "Ham" dan juga diprediksi sebagai "Ham" oleh model (True Negative).
    - 4: Jumlah email yang sebenarnya "Ham" tetapi diprediksi sebagai "Spam" oleh model (False Positive).
    - 293: Jumlah email yang sebenarnya "Spam" tetapi diprediksi sebagai "Ham" oleh model (False Negative).
    - 10: Jumlah email yang sebenarnya "Spam" dan juga diprediksi sebagai "Spam" oleh model (True Positive).
- Warna: Warna pada kotak-kotak menunjukkan jumlah email dalam kategori tersebut, dengan gradasi warna biru yang menunjukkan skala nilai.

Interpretasi:

- Model ini memiliki kinerja yang baik dalam mengklasifikasikan email "Ham", dengan 738 email yang terklasifikasi dengan benar sebagai "Ham" (True Negative) dan hanya 4 email yang salah diklasifikasikan sebagai "Spam" (False Positive).
- Model ini juga cukup baik dalam mengklasifikasikan email "Spam", dengan 283 email yang terklasifikasi dengan benar sebagai "Spam" (True Positive) dan 10 email yang salah diklasifikasikan sebagai "Ham" (False Negative).

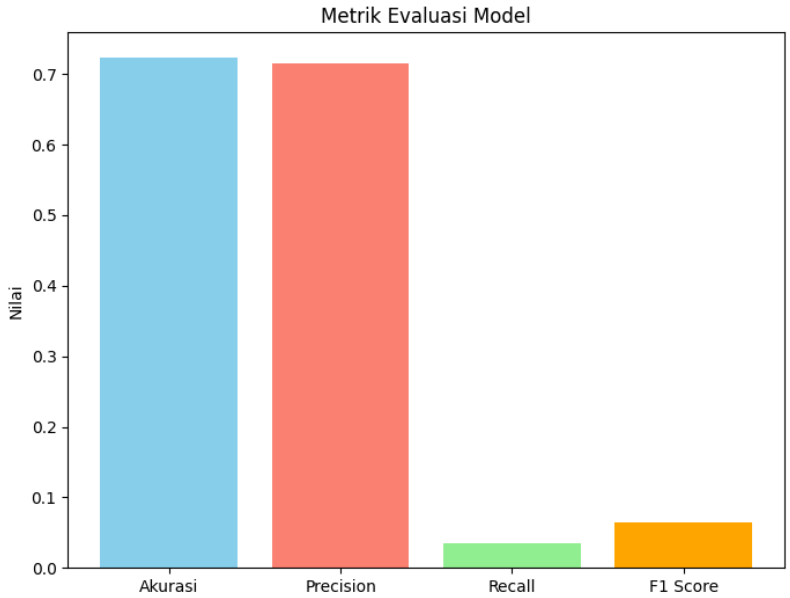

Gambar 8 metrik evaluasi model

Interpretasi:

- Akurasi (Accuracy): Mencapai nilai mendekati 1.0, yang berarti model memiliki tingkat akurasi yang sangat tinggi dalam memprediksi data dengan benar.
- Presisi (Precision): Juga mendekati 1.0, menunjukkan bahwa model memiliki tingkat presisi yang sangat baik dalam memprediksi data positif dengan tepat.
- Recall: Jauh dari 1.0, artinya model belum mampu mengidentifikasi sebagian besar data positif dengan benar.
- F1 Score: Jauh 1.0, ini adalah harmonik mean dari presisi dan recall, yang mengindikasikan bahwa model memiliki keseimbangan yang kurang baik antara presisi dan recall.

Berdasarkan pada gambar 8 ini, dapat disimpulkan bahwa model klasifikasi ini memiliki kinerja yang sangat baik pada akurasi dan presisi karena pada matrik evaluasi menunjukan nilai yang sangat tinggi mendekati 1.0. tetapi untuk recall dan F1 score menujukan nilai yang sangat rendah.

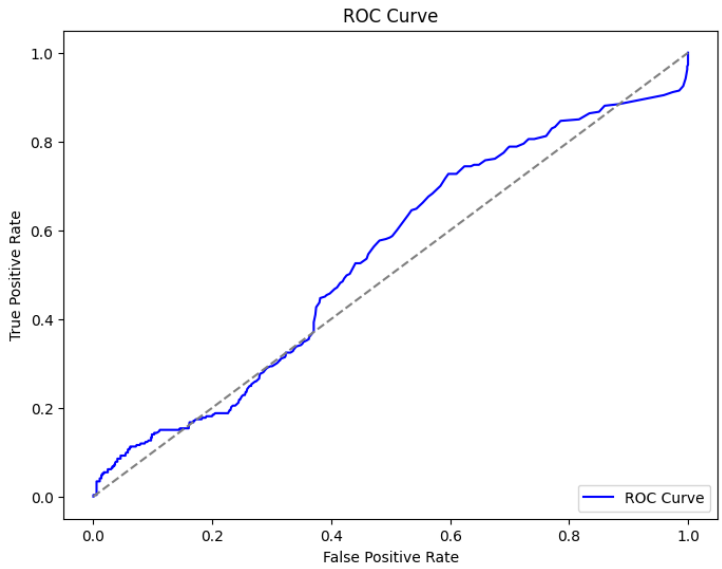

Gambar 9 ROC Curve

Interpretasi:

Kurva ROC yang tidak jauh dari garis diagonal menunjukkan bahwa model tidak terlalu baik dalam membedakan spam dan non-spam.

4. KESIMPULAN

Berdasarkan hasil penelitian yang diperoleh, dapat disimpulkan bahwa penggunaan Generative Pre-trained Transformer (GPT) dalam ekstraksi fitur secara signifikan meningkatkan performa model regresi logistik dalam mendeteksi email spam dibandingkan dengan model tanpa ekstraksi fitur.

Hasil pada Tabel 1 menunjukkan bahwa model dengan ekstraksi fitur menggunakan GPT mencapai akurasi sebesar 97.58%, jauh lebih tinggi dibandingkan model tanpa ekstraksi fitur yang hanya memiliki akurasi sebesar 72.27%. Selain itu, metrik evaluasi lainnya seperti presisi, recall, F1-score, dan ROC AUC juga mengalami peningkatan yang signifikan.

Peningkatan recall dari 34.12% menjadi 95.90% menunjukkan bahwa model dengan GPT mampu mengidentifikasi lebih banyak email spam secara akurat, mengurangi kemungkinan spam lolos sebagai email normal. Begitu pula dengan peningkatan nilai ROC AUC dari 0.5365 menjadi 0.9935 yang menunjukkan bahwa model dengan GPT memiliki kemampuan klasifikasi yang jauh lebih baik dibandingkan model tanpa ekstraksi fitur.

Dengan demikian, dapat disimpulkan bahwa ekstraksi fitur menggunakan GPT berkontribusi secara positif dalam meningkatkan efektivitas model regresi logistik untuk deteksi email spam. Implementasi GPT dalam ekstraksi fitur dapat menjadi pendekatan yang sangat direkomendasikan untuk meningkatkan performa model klasifikasi berbasis teks, khususnya dalam domain keamanan siber dan filterisasi spam.

DAFTAR RUJUKAN

[1] E. Ismaredah, "KEAMANAN E-MAIL MENGGUNAKAN METODE ENKRIPSI GNUPG DENGAN SQUIRELLMAIL DAN THUNDERBIRD." [Online]. Available: www.keys.pgp.net

[2] K. 4a4 and O. Iskandar, "ANALISIS KEJAHATAN ONLINE PHISHING PADA MASYARAKAT," 2024.

[3] M. H. Wibowo and N. Fatimah, "ANCAMAN PHISHING TERHADAP PENGGUNA SOSIAL MEDIA DALAM DUNIA CYBER CRIME," 2017.

[4] A. Raup, W. Ridwan, Y. Khoeriyah, Q. Yuliati Zaqiah, and U. Islam Negeri Sunan Gunung Djati Bandung, "Deep Learning dan Penerapannya dalam Pembelajaran." [Online]. Available: http://Jiip.stkipyapisdompu.ac.id

[5] M. Haris, T. Pustaka, M. H. Diponegoro, S. Kusumawardani, and I. Hidayah, "Tinjauan Pustaka Sistematis: Implementasi Metode Deep Learning pada Prediksi Kinerja Murid (Implementation of Deep Learning Methods in Predicting Student Performance: A Systematic Literature Review)," 2021.

[6] N. Suarna and W. Prihartono, "PENERAPAN NLP (NATURAL LANGUAGE PROCESSING) DALAM ANALISIS SENTIMEN PENGGUNA TELEGRAM DI PLAYSTORE," 2024.

[7] P. M. Prihatini, "IMPLEMENTASI EKSTRAKSI FITUR PADA PENGOLAHAN DOKUMEN BERBAHASA INDONESIA The Implementation of Extraction Feature on Indonesian Documents' Processing," 2016.

[8] D. H. Putra, G. Wahyu, and I. Noto, "IMPLEMENTASI GENERATIVE PRE-TRAINED TRANSFORMERS 2 UNTUK MENGOREKSI KESALAHAN PENULISAN BAHASA INDONESIA PADA DOKUMEN JURNAL."

[9] M. Rustam, A. Brotokuncoro, and R. Roestam, "DETEKSI EMAIL SPAM DENGAN CONTINUOUS BAG-OF-WORDS DAN RANDOM FOREST," 2024.

[10] G. M. Shahariar, S. Biswas, F. Omar, F. M. Shah, and S. Binte Hassan, "Spam Review Detection Using Deep Learning," in *2019 IEEE 10th Annual Information Technology, Electronics and Mobile Communication Conference, IEMCON 2019*, Institute of Electrical and Electronics Engineers Inc., Oct. 2019, pp. 27–33. doi: 10.1109/IEMCON.2019.8936148.

[11] A. R. Openai, K. N. Openai, T. S. Openai, and I. S. Openai, "Improving Language Understanding by Generative Pre-Training." [Online]. Available: https://gluebenchmark.com/leaderboard

[12] A. Purnama and D. Hamidin, "Metode Algoritma Logistic Regression dalam Klasifikasi Email Spam," *JOURNAL SHIFT VOL*, vol. 5, 2025, [Online]. Available: https://www.kaggle.com/

[13] T. B. Brown *et al.*, "Language Models are Few-Shot Learners." [Online]. Available: https://commoncrawl.org/the-data/

[14] F. Reviantika, Y. Azhar, and G. I. Marthasari, "Analisis Klasifikasi SMS Spam Menggunakan Logistic Regression," APIC, 2021. [Online]. Available: https://www.cnbcindonesia.com

[15] K. Kristiawan and A. Widjaja, "Perbandingan Algoritma Machine Learning dalam Menilai Sebuah Lokasi Toko Ritel," *Jurnal Teknik Informatika dan Sistem Informasi*, vol. 7, no. 1, Apr. 2021, doi: 10.28932/jutisi.v7i1.3182.

[16] M. Garg and M. Gupta, "Email Spam Detection Using Logistic Regression," *Journal of Pharmaceutical Negative Results ¦*, vol. 13, doi: 10.47750/pnr.2022.13.S10.245.

[17] F. Reviantika, Y. Azhar, and G. I. Marthasari, "Analisis Klasifikasi SMS Spam Menggunakan Logistic Regression," *REPOSITOR*, vol. 3, no. 4, pp. 387–392, 2021, [Online]. Available: https://www.cnbcindonesia.com

[18] B. B. Tangkere, "Analisis Performa Logistic Regression dan Support Vector Classification untuk Klasifikasi Email Phising", doi: 10.38035/jemsi.v5i4.

[19] M. Sari and G. Mahalisa, "Naive Bayes Classifier Untuk Deteksi Email Spam," *Technologia : Jurnal Ilmiah*, vol. 15, no. 4, p. 675, Oct. 2024, doi: 10.31602/tji.v15i4.15944.

[20] S. Si, Y. Wu, L. Tang, Y. Zhang, and J. Wosik, "Evaluating the Performance of ChatGPT for Spam Email Detection," Feb. 2024, [Online]. Available: http://arxiv.org/abs/2402.15537

[21] F. D. Pramakrisna, F. D. Adhinata, and N. A. F. Tanjung, "Aplikasi Klasifikasi SMS Berbasis Web Menggunakan Algoritma Logistic Regression," *Teknika*, vol. 11, no. 2, pp. 90–97, Jun. 2022, doi: 10.34148/teknika.v11i2.466.

[22] U. Almarisah Madani, "Analisis Performa Algoritma Klasifikasi untuk Deteksi Spam pada Email Thiara Tri Funny Manguma 1✉ , Emil Fatra 2," *INNOVATIVE: Journal Of Social Science Research*, vol. 4, pp. 16461–16465.

[23] S. Mutmainnah, T. Ansyor Lorosae, and S. Ramadhan, "Model Text Embedding dan TF-IDF+Ngram untuk Meningkatkan Kinerja Algoritma Binary Classifier pada Klasifikasi SMS Palsu," vol. 4, no. 1, pp. 55–64, 2025, [Online]. Available: https://ojs.trigunadharma.ac.id/index.php/jsi

[24] F. Rozi, R. Kartadie, J. Pendidikan Teknologi Informasi, and S. PGRI Tulungagung Jl Mayor Sujadi Timur no, "DETEKSI E-MAIL DAN SPAM MENGGUNAKAN FUZZY ASSOCIATION RULE MINING."

[25] F. Noer Azzahra *et al.*, "Penerapan Metode Naive Bayes Dalam Klasifikasi Spam SMS Menggunakan Fitur Teks Untuk Mengatasi Ancaman Pada Pengguna," *Journal of Information System Research (JOSH)*, vol. 5, no. 3, p. 880, 2024, doi: 10.47065/josh.v5i3.5070.